**Детский технопарк «Альтаир»**
**(РТУ МИРЭА)**

«Прикладной анализ данных»

# ОПИСАНИЕ ПРОЕКТА

## «Умный экстрактор документов „Книжный Червь“»

Верниковский Виталий Викторович
Ученик группы ТДИ-02-26

Руководитель: Борисов Артём Игоревич
Преподаватель детского технопарка «Альтаир» РТУ МИРЭА

Москва, 2026

## Название проекта

Умный экстрактор документов «Книжный Червь».

## Идея проекта

На вход подаётся группа PDF-документов. Локальная языковая модель с помощью предоставленных ей инструментов разделяет эти документы на части по темам и раскладывает полученные тематические блоки по листьям смыслового графа. Затем модель пишет подробный конспект по каждой теме. После этого создаются инструменты обращения к подобным графам конспекта, что должно позволить даже слабой модели показать значительно большее качество на профильной теме.

Ключевое отличие от классического RAG — не поиск отдельных фрагментов похожего текста, а сжатие всего корпуса в точный и связный конспект с ответственным разделением материала на темы. Именно качество этой компрессии и аккуратность тематической разбивки определяют точность ответов.

## Описание работы проекта

Первая часть проекта принимает в себя пакет PDF-файлов, а на выходе выдаёт сжатый, насыщенный конспект в формате графа. Вторая часть проекта представляет собой набор инструментов для языковой модели, позволяющий эффективно использовать подобный конспект для улучшения качества ответов.

Сначала документы преобразуются в структурированное знание — граф тем и конспект, — а затем языковая модель получает инструменты обращения к нему. Обе части работают в связке и обеспечивают единый путь от набора файлов до точного ответа по нужной теме.

## Актуальность

Проект позволяет улучшить качество языковой модели в определённой области знаний без дополнительных затрат на дообучение, а также позволяет модели лучше ориентироваться в специфичных корпоративных задачах при предоставлении соответствующей документации.

Классический RAG решает эту задачу иначе: он разбивает документы на небольшие фрагменты и подбирает к запросу несколько наиболее похожих. Такой подход работает, но теряет целостность материала: остаётся много лишнего и упускается значимое, а темы перемешаны между фрагментами. Данный проект делает акцент на двух вещах, которых как раз не хватает RAG, — на точной компрессии данных в конспект и на ответственном разделении материала на темы. За счёт этого ответы получаются полнее и точнее, что особенно важно при работе с большими техническими и корпоративными корпусами документов.