Умный экстрактор документов «Книжный Червь»

Проект выполнил(а):

Верниковский Виталий Викторович

ГБОУ Школа № 1329,
10 «Т» класс

Руководитель проекта:

Преподаватель ДТ «Альтаир»

БОРИСОВ АРТЁМ ИГОРЕВИЧ

Актуальность

Языковые модели ошибаются в узких темах без доступа к проверенным источникам.

Классический RAG используется для улучшения ответов модели на фактологических задачах, но почти не влияет на решение качественных задач.

Проект сжимает корпус PDF-документов в связный конспект и смысловой граф тем.

Это повышает точность ответов на качественных задачах без дообучения.

Цель

Создать и оценить алгоритм, альтернативный классическому RAG, для повышения точности ответов модели на профильных задачах.

Задачи

1. Сбор корпуса PDF-документов из открытых источников
2. Преобразование документов в очищенный текст и смысловой граф тем
3. Создание инструментов обращения к графу и конспекту для ИИ-агента
4. Тестирование и сравнение с классическим RAG

Методика выполнения работы

1. Сбор корпуса: поиск открытых PDF-документов и отбор релевантных источников.
2. Извлечение текста: Docling и PyMuPDF, OCR и распознавание формул, очистка от колонтитулов и мусора.
3. Структурирование: разбиение материала на темы, построение смыслового графа и конспект по каждой теме.
4. Инструменты и оценка: доступ ИИ-агента к графу, бенчмарк и сравнение с классическим RAG.

Материалы

Открытые PDF-корпуса: учебники, научные статьи и книги открытого доступа.

Научные публикации по RAG, графам знаний и обработке документов.

Оборудование и ПО

Ollama - для запуска модели

Python 3 - язык разработки.

Модели Qwen3.8-27B, Qwen3.5-4B и GPU NVIDIA RTX 3060.

Библиотеки: Docling, PyMuPDF, DuckDuckGo Search, Git.

Что будет?

Результатом работы станет полный пайплайн, который включает:

1. Автоматический механизм сбора корпуса PDF-документов
2. Алгоритм построения смыслового графа и конспекта
3. Инструменты обращения к графу и конспекту для ИИ-агента
4. Бенчмарк сравнения с классическим RAG и оформленные результаты

Список использованных источников

- Lewis, P., Perez, E., Piktus, A., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. arXiv:2005.11401.
- Edge, D., Trinh, H., Cheng, N., et al. (2024). From Local to Global: A Graph RAG Approach to Query-Focused Summarization. ArXiv:2404.16130.
- Документация Ollama — https://docs.ollama.com/
- Документация Docling — https://docling-project.github.io/docling/
- Документация PyMuPDF — https://pymupdf.readthedocs.io/
- DuckDuckGo Search (ddgs) — https://pypi.org/project/ddgs/